

人工智能导论期末复习

Chap 1. 搜索问题

一、盲目搜索

1. 深搜 (return 路径或 Fail)

判断 < 到目标， return null.

走到头 Fail.

应用规则获得可走集合，若为空， return Fail.

↓

取第一个继续走 (...)

2. 宽搜 (G-搜索图, OPEN-队列, CLOSED-已搜过)

二、启发式图搜索

1. * A算法 (OPEN表按 f 值从小到大排序)，注意扩展 n 时要更新有父的 m_k, m_i (OPEN)


★ 终止条件：OPEN表取出第一个，为 goal.

2. * A* : $h(n) \leq h^*(n)$ ，改进 $h(n) - h(m_i) \leq c(n, m_i)$ ($m_i \in \text{EXPAND}(n)$)

• 改进 A* 的 $f_m = \max f(n_i)$, $n_i \in \text{CLOSED}$

利用 f_m 划分出 OPEN 的子集 NEST 为 $f(n_i) < f_m$ 的 $f(n_i)$ ，优先其中 $f(n_i)$

[例]



OPEN表

S(0+9)

C(1+8), B(3+5), A(6+1)

C(1+8), A(4+1)

C(1+8), G(1+0)

B(2+5), G(12+0)

A(3+1), G(12+0)

G(11+0)

CLOSED表

S(0+9)

S(9)

S(9), B(8)

S(9), B(8), A(5)

S(9), B(8), A(5), C(9)

S(9), B(8), A(5), C(9), B(2+5)

S, B₈, A₅, C₉, B₇, A₃₊₁

f_m

9

9

9

9

9

9

9

注意范围 f_m

$f_m = f(n) = 9$

NEST 定义, $n = 1st$

end. □

三、动态规划 ($h=0$)

viterbi 算法：遍历 parent 可确定从根经 P 到 V 的最优 P_V 。
(称为 GP)

Chap 2. 对抗搜索

一. * α - β 剪枝

极大：己方选择，必选分数极大的；极小：对方选择分数极小的
 (即对自己) (即己方)

▲ 走步标记：只能走一步


剪枝： α 剪枝即 MAX 节点的孙子 $\leq \alpha$ 时，孙子的父亲被剪。

β 剪枝即 MIN 孙子 $\geq \beta$

[例 1] MAX

MIN

MAX




(α 剪枝)

(MAX 的下界 \leq 祖父，则其父 MIN \leq 祖父，必不选)
 评估局面变差

MIN

MAX


MIN



(β 剪枝)

评估局面减弱 (MIN 的上界超过祖父，则其父 MAX \geq 祖父，必不被选)

[例 2]



二. 蒙特卡罗树搜索

可扩展

区别：MCTS 随机落子，UCT 按信心上限选（先扩展，不可就 Best Child）

(\bar{X}_j 平均收益， $I_j = \bar{X}_j + C \sqrt{\frac{2 \ln n}{T_j(n)}}$ (访问次数占比))

Chap 3. 高级搜索

一. 局部搜索 (~梯度下降)

问题
局部最优 (收敛到 local max 但非全局) \Rightarrow 按概率选点 (优 P 大)
步长 (learning rate 太大会难收敛) $\xrightarrow{\min}$ 变步长
起始点 \Rightarrow 随机生成多个起始点, 优中选优

二. 模拟退火

1. 状态转移

① 低能方向 (好的点): 一定转移 (Random $< P_0$, 移动 V)

② 高能方向 (差的点): 按概率转移, 接受概率 $P_0 = e^{-\frac{\Delta E}{KT}}$ ($\Delta E > 0$)
T - 温度
K - 玻尔兹曼常数

2. 初温温度: $t_0 = \frac{\Delta f(i,j)}{\ln(P_0)}$, P_0 为给定较大的接受概率,

估计 $\Delta f(i,j) = \max_{i \in S} f(i) - \min_{j \in S} f(j)$, S 为随机产生的序列

温度下降: 等比例 \downarrow , $t_{k+1} = \alpha t_k$, $\alpha \in (0, 1)$.

结束条件 \leftarrow 温度下平衡条件: 固定长度 L_k (?)

算法停止: 零度法, 设定 $\varepsilon > 0$, $t_k < \varepsilon \Rightarrow \text{end}$.

[例] a, b, c, d 依次产生的状态, $f(a)=10$, $f(b)=20$, $f(c)=30$, $f(d)=20$.

算法循环 3 次, $t=10$ 不变, 随机数依次为 0.5, 0.1, 0.01, 0.2, 来得.

| ①. $f(i) = f(a)$ 次序 | i | j | $f(i)$ | $f(j)$ | P | Random | |
|---------------------------------------------------------|---|---|--------|--------|-----------------------------|--------|-----|
| | | | | | | 0.5 | 0.1 |
| ① | a | b | 10 | 20 | $e^{-\frac{10}{10}} = 0.37$ | 0.5 | x |
| ② | a | c | 10 | 30 | $e^{-\frac{20}{10}} = 0.14$ | 0.1 | ✓ |
| ③ | c | d | 30 | 20 | 1 (低能 v) | 0.01 | ✓ |

最后的解为 d.

三. 遗传算法

1. 编码：数字取值有16个，可以用4位二进制数；
 (矩阵展开) 也可以用十进制。

2. 选择：轮盘赌法，选择概率 $P(X_i) = \frac{f(x_i)}{\sum f(x)}$ 选择

交叉：二进制时，双亲在交叉位置后的完全对换 ($\begin{array}{c} 10 \\ 01 \end{array} \rightarrow \begin{array}{c} 01 \\ 10 \end{array}$)

变异：二进制，变异位置 $0 \rightarrow 1 / 1 \rightarrow 0$

3. 适应函数 — (一般) 问题指标函数 $f(x)$

(f_m 固定 f_{\max}) 加速 $f_1(x) = \begin{cases} \frac{1}{f_{\max} - f(x)}, & f(x) < f_{\max} \\ M, & \text{else} \end{cases}$

线性 $f_2(x) = \alpha f(x) + \beta$

△ 十进制交叉： $2P \rightarrow 2F$, F_1 前半取 P_1 , 后半按顺序选 P_2 (剩余的) 的。

变异：2个位置，后一移到前一前面。

4. 结果：全局最优解 (每次保留全过程中最好的)

[例] 编码方案：(x_1 ~ x_4)，求 $f(x) = x$ 最大值。 (随机数 0.2, 0.7, 0.67, 0.9, 0.5)

个体 1 初始群体 编码 适应值 选择概率 选中次数

① 分母为群体

适应值之和，

即 $1+13+4+9=37$

1

11

1010

11

$(0.3) \frac{11}{37} / \cancel{11} = \frac{11}{37}$

1

2

13

1100

13

$(0.35) \frac{13}{37} / \cancel{13} = \frac{13}{37}$

0

3

4

0011

4

$(0.11) \frac{4}{37} / \cancel{4} = \frac{4}{37}$

2 可以
重复

4

9

1000

9

$(0.24) \frac{9}{37} / \cancel{9} = \frac{9}{37}$

1

△ 模拟轮盘赌 (把轮盘展开) $\boxed{① 0.3 \quad ② 0.65 \quad ③ 0.76 \quad ④ 1}$

(和为 $N=4$)

① $r = \text{random} = 0.2$, ① \Rightarrow ② $r=0.7$, ③ \checkmark ③ $r=0.67$, ③, ④ $r=0.9$, ④

$(x_b = 1100(13))$.

→ (新群体)

△ (交叉位是 n , 表明 $a_1 \dots a_n | a_{n+1} \dots a_m$)

给定交叉对象，交叉位 子代 子代适应值

1

1010

2

1011

12

2

0011

2

0010

3

3

0011

3

0010

3

4

1000

3

1001

10

$x_b = 1100(13)$ 不变，解码的编码为 1100，解码后 $x = 13$.

Chap 4. 统计机器学习

一.朴素贝叶斯

1. 训练/学习过程就是统计 & 求概率.

① 各类概率 $P(Y=C_k) = \frac{\sum_{i=1}^N I(y_i=C_k)}{N+K\lambda}$ (K个类), 频率决定概率.

② 条件概率

$$P(X^{(j)}=a_{jl} | Y=C_k) = \frac{\sum_{i=1}^N I(x_i^{(j)}=a_{jl}, y_i=C_k)}{\sum_{i=1}^N I(y_i=C_k)+\lambda}$$

有特征 a_{jl} 的 C_k 类数量
 C_k 类总数

2. 分类时的概率 (归一化, 去分子)

$$P'(Y=C_k | X=x) = P(Y=C_k) \cdot \prod_{j=1}^n P(X^{(j)}=x^{(j)} | Y=C_k), \quad y = \arg \max_{C_k} P'_k.$$

(条件已知特征为 X)

(认为每个特征独立, 相乘计算)

二. 支持向量机 (SVM)

1. 线性可分 SVM

① 内积

$$\text{对偶问题: } \min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i, \quad \text{s.t. } \sum_{i=1}^N \alpha_i y_i = 0, \quad \alpha_i \geq 0$$

$$\Rightarrow w^* = \sum_{i=1}^N \alpha_i^* y_i x_i, \quad b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j)$$

求 \min : 偏导为 0 再求解, 若不满足约束 $\alpha_i \geq 0$, 则在边界 (某 $\alpha=0$)

[例 1] $N=3$, 正例 $x_1=(1, 0)^T$, 负例 $x_2=(4, 3)^T$, $x_3=(2, 1)^T$, 未最大间隔

对偶行 $\min_{\alpha} \frac{1}{2} (\alpha_1^2 + 25\alpha_2^2 + 5\alpha_3^2 - 8\alpha_1\alpha_2 - 4\alpha_1\alpha_3 + 22\alpha_2\alpha_3) - \sum \alpha_i$ 超乎意料

~~令偏导为 0 得~~ $s.t. \alpha_1 - \alpha_2 - \alpha_3 = 0$, 代入 $\alpha_1 = \alpha_2 + \alpha_3$ 得

$$S(\alpha_2, \alpha_3) = \frac{1}{2} (26\alpha_2^2 + 6\alpha_3^2 - 8\alpha_2^2 - 8\alpha_2\alpha_3) - \frac{1}{2} ((\alpha_2 + \alpha_3)^2 - 4(\alpha_2 + \alpha_3)(2\alpha_2 + \alpha_3) + \dots)$$

$$= \frac{1}{2} (\alpha_2^2 + 2\alpha_2\alpha_3 + 3\alpha_3^2 - 8\alpha_2^2 - 4\alpha_3^2 - 12\alpha_2\alpha_3 + \dots)$$

$$= 25\alpha_2^2 + 22\alpha_2\alpha_3 + 5\alpha_3^2 - 2\alpha_2 - 2\alpha_3$$

$$= 9\alpha_2^2 + 4\alpha_3^2 + 6\alpha_2\alpha_3 - 2\alpha_2 - 2\alpha_3$$

② 无解

$$\text{令偏导为 0 得 } \begin{cases} \frac{\partial S}{\partial \alpha_2} = 18\alpha_2 + 6\alpha_3 - 2 = 0 \\ \frac{\partial S}{\partial \alpha_3} = 4\alpha_3 + 6\alpha_2 - 2 = 0 \end{cases} \Rightarrow \begin{cases} \alpha_2 = -\frac{1}{9} \\ \alpha_3 = \frac{2}{3} \end{cases} \times \text{在边界}$$

$$\alpha_2 = 0 \text{ 时, } \min S(\alpha_3) = S(0, \frac{2}{3}) = -\frac{1}{9} \checkmark$$

$$\alpha_3 = 0 \text{ 时, } S(\frac{1}{9}, 0) = -\frac{1}{9}$$

$$\Rightarrow \alpha_1 = 0 + \frac{1}{9} = \frac{1}{9}, \quad \alpha_2 = 0, \quad \alpha_3 = \frac{1}{3}, \quad x_1, x_3 \text{ 为支持向量}$$

$$w^* = \frac{1}{9}(x_1 - x_3) = (-\frac{1}{9}, -\frac{1}{3}), \quad b^* = 1 - (\frac{1}{9}x_1^2 - \frac{1}{9}(x_1 \cdot x_3)) = 1 - (\frac{1}{9} - \frac{1}{3}) = \frac{1}{3}$$

分离超平面为 $w^*x + b^* = 0$, 即 $-\frac{1}{9}x^{(1)} - \frac{1}{3}x^{(3)} + \frac{1}{3} = 0$

$$\text{分类决策函数 } f(x) = \text{sign}(-\frac{1}{9}x^{(1)} - \frac{1}{3}x^{(3)} + \frac{1}{3})$$

2. 非线性SVM 线性SVM(某些点不可分, 引入松弛变量 ξ_i)

对偶问题与 min 相同, s.t. $\sum \alpha_i y_i = 0$, $0 \leq \alpha_i \leq C$

求得最优解后计算 w^* (向量), 选择 $\alpha_j^* \in (0, C)$ 并 b^* .

~~$\alpha_i^* > 0$~~ , x_i 为支持向量

$$\begin{cases} < C \text{ 则 } \xi_i = 0, x_i \text{ 在边界} \\ = C \text{ 若 } \xi_i \in (0, 1), \text{ 则分类 } \checkmark \\ \xi_i = 1 \quad \text{则在超平面上} \\ > 1 \quad \text{则误分} \end{cases}$$

3. 非线性 SVM

利用核函数映射为超平面

对偶时内积 $(x_i \cdot x_j)$ 替换为 $K(x_i, x_j)$

三. 决策树

熵 $H(X) = -\sum p_i \log p_i$, $p_i = P(X=x_i)$, $H(D) - p_i$ 由数据集 D 得到

$$\begin{aligned} \text{条件熵 } H(Y|X) &= \sum p_i H(Y|X=x_i) = \sum \frac{|D_i|}{|D|} H(D_i) \quad (p_i = \frac{|C_i|}{|D|}) \\ &= -\sum_{i=1}^c \frac{|D_i|}{|D|} \sum_{k=1}^{|C_i|} \frac{|D_{ik}|}{|D_i|} \log \frac{|D_{ik}|}{|D_i|}. \quad (\text{全集中弃各类 } p_i) \end{aligned}$$

信息增益 (特征 A 对数据集 D): $g(D, A) = H(D) - H(D|A)$ (特征子集中弃各类 p_i)

1. ID3

按特征划分的子集

先判断: ①不必再分? ($A \in C_k$ 类) \rightarrow 单节点树 T, 标 C_k

②特征不够? (A 为空) \rightarrow 单节点树 T, 标最多实例的 C_k

③(信息增益 $<$ 阈值 ε) \rightarrow 单节点树 T, 一般多 C_k

特征有但不明显?

否则按 A_g 的所有可能分类分裂 D_i ,

若某 D_i 为空 (该特征取值下, 一个实例也无), 标为 D 中嵌入 C_k

否则以 D_i 为训练集, $A - \{A_g\}$ 为特征集, 递归 (return 子树 i)

2. C4.5

根据信息增益比, 除以 $H_A(D) = -\sum_{k=1}^c \frac{|D_k|}{|D|} \log \frac{|D_k|}{|D|}$, 对多分支特征惩罚

对连续属性找到一个分界值 a_0 , $\leq a_0$, $> a_0$.

3. 后剪枝 (验证集上测试剪枝, 训练集是 original DT)

↑ 数据也可直接在 training set 上

Chap 5. 神经网络及深度学习

WAN

一. 神经元

$$O = \sigma(\sum_{i=0}^n w_i x_i) = \sigma(\vec{w} \cdot \vec{x})$$

$$\text{误差函数(整个训练集)} E(\vec{w}) = \frac{1}{2} \sum_{d \in D} \sum_{k \in \text{outputs}} (t_{k,d} - o_{k,d})^2$$

二. BP算法:

$$E_d(\vec{w}) = \frac{1}{2} \sum_{k \in \text{outputs}} (t_{k,d} - o_{k,d})^2, \Delta w_{ji} = -\eta \frac{\partial E_d}{\partial w_{ji}}, \eta \in (0, 1)$$

$$\text{由链式法则, } \frac{\partial E_d}{\partial w_{ji}} = \frac{\partial E_d}{\partial \text{net}_j} \cdot \frac{\partial \text{net}_j}{\partial w_{ji}} = \frac{\partial E_d}{\partial \text{net}_j} x_{ji} \quad (\text{net}_j = \sum_l w_{jl} x_{jl})$$

分输出层、隐含层计算 $\frac{\partial E_d}{\partial \text{net}_j}$.

三. CNN

卷积: 对应位置 \times 再 \oplus . \star 注意 $O_j = \text{kernel} \oplus \sigma(\text{net}_j)$

激活函数 (ReLU 取 ≥ 0)

Δ 记得 $+ b$!

四. 各种Net (见 byz 笔记)

五. 过拟合解决

正则项 (L_1, L_2), Dropout, 验证集

六. 梯度消失 (解决: ReLU / 改善网络结构 [GoogleNet])

Sigmoid 导数 ≤ 1 , 层数深了越乘越小.

② 为什么 $|w_{kh}|$ 太大会导致 $O_h \approx 0$, 过大导致梯度爆炸?

▷

七. word2vec

上下文 MLE, BP求解 $\max_{\theta} (\sum_{w \in C} \log F(w, \text{context}(w), \theta))$

① CBOW: 2C 大小的窗口,

求和作为 context, $\text{Bp } x_w = \sum_{i=1}^{2C} \text{context}(w)_i$

② Huffman 树: 输入 x_w , 输出概率 (按每层向左/右做 softmax, 累乘)

$$\Rightarrow \text{Loss} = -\log \prod_{i=2}^{2C} p(d_i^w | x_w, \theta_{ij}^w) = -\sum_{i=2}^{2C} \left[(1-d_i^w) \log [\sigma(x_w^T \theta_{ij}^w)] + d_i^w \log [1-\sigma(x_w^T \theta_{ij}^w)] \right]$$

(根无01编码) 才好

(左0右1)

每个节点不同
doallen

A. RNN

BP求导：交叉熵 + softmax.

$$(1) \text{ 输出层 } ① \frac{\partial H_t}{\partial net_j} = \sum_i \frac{\partial H_t}{\partial o_i} \cdot \frac{\partial o_i}{\partial net_j} \quad (\text{链式} + \text{Jacobi AE 阵})$$

$$② \frac{\partial H_t}{\partial o_i} = -\frac{t_i}{o_i}, \quad \frac{\partial o_i}{\partial net_j} = \begin{cases} (i=j) & o_j(1-o_j) \\ (i \neq j) & -o_j \cdot o_i \end{cases}$$

$$\Rightarrow \sum_i \frac{\partial H_t}{\partial o_i} \cdot \frac{\partial o_i}{\partial net_j} = \sum_{i \neq j} \left(-\frac{t_i}{o_i} \right) \cdot (-o_j \cdot o_i) + \left(-\frac{t_j}{o_j} \right) \cdot o_j(1-o_j)$$

$$= \sum_{i \neq j} t_i \cdot o_j - t_j(1-o_j) = \sum_{i \neq j} t_i o_j + t_j o_j - t_j$$

$$= \sum_i t_i o_j - t_j = o_j \sum_i t_i - t_j$$


$$(2) \text{ 隐含层 } ① \frac{\partial H_t}{\partial net_j} = \sum_{k \in \text{Downstream}(j)} \frac{\partial H_t}{\partial net_k} \cdot \frac{\partial net_k}{\partial net_j}, \quad \text{IRD} \quad \frac{\partial net_k}{\partial net_j} = \sum_i \frac{\partial net_k}{\partial o_i} \cdot \frac{\partial o_i}{\partial net_j}$$

$$② \frac{\partial net_k}{\partial o_i} = W_{ki}, \quad \frac{\partial o_i}{\partial net_j} \quad (\text{见上})$$


$$\Rightarrow \sum_i \frac{\partial net_k}{\partial o_i} \cdot \frac{\partial o_i}{\partial net_j} = \sum_{i \neq j} W_{ki} \cdot (-o_j o_i) + W_{kj} o_j (1-o_j) = W_{kj} o_j - q \sum_i W_{ki} o_i$$

$$\Rightarrow \frac{\partial H_t}{\partial net_j} = \sum_{k \in \text{Downstream}(j)} \frac{\partial H_t}{\partial net_k} \cdot (W_{kj} o_j - o_j \sum_i W_{ki} o_i)$$

[例] - α - β



α β α β



[例1] 线性可分SVM, $x_1 = (0, 0)$ 正, $x_2 = (2, 0)$, $x_3 = (0, 2)$ 负, 求 w , 对 $x_5 = (0, -1)$

$$\min_{\alpha} \frac{1}{2} (4\alpha_2^2 + 4\alpha_3^2) - (\alpha_1 + \alpha_2 + \alpha_3), \text{ s.t. } \alpha_1 - \alpha_2 - \alpha_3 = 0, \text{ 代入得}$$

$$S(\alpha_2, \alpha_3) = 2\alpha_2^2 + 2\alpha_3^2 - 2\alpha_2 - 2\alpha_3,$$

$$\text{令偏导为0 得} \begin{cases} 4\alpha_2 - 2 = 0 \\ 4\alpha_3 - 2 = 0 \end{cases} \Rightarrow \begin{cases} \alpha_2 = \frac{1}{2} \\ \alpha_3 = \frac{1}{2} \end{cases} \Rightarrow \alpha_1 = 1 \quad \text{均正} \checkmark \\ \text{且支持 vec}$$

$$\Rightarrow \text{平面: } w^* = \alpha_1 y_1 x_1 + \alpha_2 y_2 x_2 + \alpha_3 y_3 x_3 = -\frac{1}{2} \times (2, 2) = (-1, -1)$$

$$b^* = y_1 - (\alpha_1^* y_1 (x_1 \cdot x_1) + \alpha_2^* y_2 (x_2 \cdot x_1) + \alpha_3^* y_3 (x_3 \cdot x_1)) = 0.$$

$$-x_1 - x_2 = 0$$

$$f(x) = \text{sign}(-x_1 - x_2) \Rightarrow f(x_5) = \text{sign}(1) \text{ 为正例}$$

[例2] 非线性 SVM, $x_1 = 0$ 负, $x_2 = 1$, $x_3 = -1$ 正, $K(x_i, x_j) = (x_i * x_j + 1)^2$

~~\min_{α}~~ ① 先弄“内积”: $K(x_1, x_1) = 1$, $K(x_1, x_2) = 4$, $K(x_1, x_3) = 1$,

~~$K(x_2, x_3) = 0$, $K(x_2, x_2) = 4$, $K(x_3, x_3) = 4$~~

~~② $\min_{\alpha} \frac{1}{2} \sum_{i=1}^3 \sum_{j=1}^3 \alpha_i \alpha_j y_i y_j K(x_i, x_j) - \sum_{i=1}^3 \alpha_i$, s.t. $\sum_{i=1}^3 \alpha_i y_i = 0$, $\alpha_i \geq 0$~~

BP:

$$\begin{aligned} & \min_{\alpha} \frac{1}{2} (\alpha_1^2 + 4\alpha_2^2 + 4\alpha_3^2 - 2\alpha_1\alpha_2 - 2\alpha_1\alpha_3), \text{ 代入 } -\alpha_1 - \alpha_2 - \alpha_3, \text{ 得 } -\alpha_1 + \alpha_2 + \alpha_3 = 0 \\ \Rightarrow S(\alpha_2, \alpha_3) &= \frac{1}{2} ((\alpha_2 + \alpha_3)^2 + 4\alpha_2^2 + 4\alpha_3^2 - 2(\alpha_2 + \alpha_3)^2) - 2\alpha_2 - 2\alpha_3 \\ &= \frac{1}{2} (4\alpha_2^2 + 4\alpha_3^2 - \alpha_2^2 - 2\alpha_2\alpha_3 - \alpha_3^2) - 2\alpha_2 - 2\alpha_3 \\ &= \frac{3}{2}\alpha_2^2 + \frac{3}{2}\alpha_3^2 - \alpha_2\alpha_3 - 2\alpha_2 - 2\alpha_3 \end{aligned}$$

$$\text{grad } g = 0 \Rightarrow \begin{cases} 3\alpha_2 - \alpha_3 - 2 = 0 \\ 3\alpha_3 - \alpha_2 - 2 = 0 \end{cases} \Rightarrow \begin{cases} \alpha_2 = 1 \\ \alpha_3 = 1 \end{cases} \Rightarrow \alpha_1 = 2 \quad \checkmark$$

$$\Rightarrow w^* = 0 + 1 - 1 = 0,$$

$$b^* = -1 - (2|x_1| + |x_2| + |x_3|) = -1.$$

超平面:

$$w^* \text{ 没有了, 前一次是 } \sum_{i=1}^N \alpha_i^* y_i K(x_i, x) = \underbrace{\alpha_1 y_1}_{-2} (x_1 \cdot x + 1)^2 + \underbrace{\alpha_2 y_2}_{1} (x_2 \cdot x + 1)^2 + \underbrace{\alpha_3 y_3}_{1} (x_3 \cdot x + 1)^2$$

$$\begin{aligned} b^* &= y_1 - (\alpha_1 y_1 K(x_1, x_1) + \alpha_2 y_2 K(x_2, x_1) + \alpha_3 y_3 K(x_3, x_1)) \\ &= -1 - (2|x_1| + |x_2| + |x_3|) = -1. \end{aligned}$$

$$\Rightarrow f(x) = \text{sign}(-2(|x_1|)^2 + (|x_2|)^2 + (|x_3|)^2 - 1)$$